

TRƯỜNG THPT PHAN ĐÌNH PHÙNG

BẢN THUYẾT MINH
MÔ HÌNH SẢN PHẨM THAM DỰ CUỘC THI
SÁNG TẠO THANH THIẾU NIÊN NHI ĐỒNG
TOÀN QUỐC

1. Tên mô hình, sản phẩm dự thi:

“Hybrid Mamba-2+Attention World Model cho robot manipulation”

2. Lĩnh vực dự thi:

- Phần mềm tin học

3. Thông tin về tác giả, giáo viên hướng dẫn:

Tác giả:

- Họ và tên: Dương Thanh Hoan

- Lớp: 11A5.

- Trường: THPT Phan Đình Phùng –

- Số điện thoại: 0396923143 - Email: thoan4965@gmail.com

Giáo viên hướng dẫn:

- Họ và tên: Võ Thị Thanh Trúc - Số điện thoại: 0836013539

Tháng 8/ 2026

BẢN THUYẾT MINH

MÔ HÌNH SẢN PHẨM THAM DỰ CUỘC THI SÁNG TẠO THANH, THIẾU NIÊN, NHI ĐỒNG TOÀN QUỐC LẦN THỨ 22 (NĂM 2026)

I. Thông tin chung

Trường	Nội dung
Tên mô hình, sản phẩm dự thi	"Hybrid Mamba-2+Attention World Model cho robot manipulation"
Lĩnh vực dự thi	Phần mềm tin học
Tác giả	Dương Thanh Hoan — Lớp 11A5 — THPT Phan Đình Phùng — SĐT: 0396923143 — Email: thoan4965@gmail.com
Giáo viên hướng dẫn	Võ Thị Thanh Trúc — SĐT: 0836013539

Mục lục

MỤC LỤC

1. Mở đầu	2
2. Liên quan	2
3. Phương pháp	3
3.1. Kiến trúc tổng thể	3
3.2. Hình A — So sánh 3 kiến trúc bộ dự đoán	3
3.3. Hàm mất mát	7
3.4. Vì sao chọn Mamba-2	7
4. Hành trình thực nghiệm	7
4.1. V0 — Robot thật: so sánh CfC và AR	7
4.2. V1 — Hybrid CfC+Attention: phát hiện quan trọng	9
4.3. V2.1 — Hybrid Mamba-2+Attention	10
5. Kết quả	10
5.1. TwoRoom	10
5.2. Push-T	11
5.3. Đồ thị huấn luyện	12
5.4. Thử nghiệm với các tầm nhìn dài hơn	12
5.5. Thời gian giải kế hoạch bằng CEM	13
6. Thảo luận	13
6.1. ODE vs Discrete State — nguồn gốc khác biệt	13
6.2. Sai số tích lũy ở H lớn — giới hạn chung	14
6.3. So sánh với LeWM	14
6.4. Hạn chế	14
6.5. Cân nhắc khi triển khai	14
7. Kết luận và hướng nghiên cứu tiếp nối	15
7.1. Kết luận	15
7.2. Hướng nghiên cứu tiếp nối: robot nhặt rác di động	15
8. Cách sử dụng, vận hành	17
8.1. [V0 — Robot thật] Vận hành phần cứng theo cử chỉ (demo)	17
8.1.2. [V0 — Robot thật] Vận hành world model + CEM trên robot thật	17
8.2. [V2.1 — Benchmark mô phỏng] Tái lập kết quả eval	17
9. Tài liệu tham khảo	19

1. Mở đầu

Một câu đề nhớ: Robot này biết nhìn, biết nghĩ — và đang học cách tự lập kế hoạch trước khi hành động.

Lập kế hoạch hành động từ ảnh camera là bài toán cốt lõi của robot: quan sát môi trường, dự đoán hậu quả của hành động, rồi chọn chuỗi hành động tối ưu. Joint Embedding Predictive Architecture (JEPA, LeCun [1]) mở ra hướng thay thế trực tiếp: học dự đoán trong **không gian tiềm ẩn**—gọn, giàu thông tin—thay vì tái tạo từng pixel.

LeWorldModel (Maes et al. 2026) [2] hiện thực hóa JEPA với kết quả cạnh tranh (TwoRoom 87%, Push-T 96%, Cube 74%, Reacher 88%) ở 15 triệu tham số. Tuy nhiên bộ dự đoán AR (Autoregressive Transformer) của LeWM là **không trạng thái**—mỗi bước chỉ dựa trên cửa sổ 3 khung hình—nên sai số tích lũy khi tầm nhìn kế hoạch tăng, như chính paper thừa nhận: *"autoregressive rollouts accumulate prediction errors as the horizon grows"*. Chính vì vậy, thực nghiệm tại H=5 cho thấy khoảng cách đáng kể: LeWM AR đạt 88% trong khi kiến trúc lai có trạng thái trong nghiên cứu này đạt **$94.7\% \pm 3.1\%$** (kết quả chi tiết tại §5).

Hành trình đến kết quả đó không thẳng một đường: tôi bắt đầu bằng giả thuyết bộ dự đoán **có trạng thái** sẽ chạy chuỗi dài tốt hơn, kiểm chứng trên **robot thật tay bionic 8-DOF tự chế**; sau đó chạm phải một hiện tượng bất ngờ khi đưa CfC (trạng thái ODE liên tục) vào JEPA—không phải do CfC yếu, mà do **tương tác giữa SIGReg và trạng thái ODE**—và cuối cùng thay thành phần đó bằng **Mamba-2** (Dao & Gu 2024) [4], với kiến trúc $6 \times \{\text{Self-Attention(AdaLN)} \rightarrow \text{Mamba-2}\}$. Toàn bộ hành trình này được trình bày tại §4.

Ba đóng góp chính:

1. **Scheduled Sampling cho CfC-ODE-RNN** — kỹ thuật lần đầu được áp dụng cho loại mô hình này (chi tiết §4.1).
2. **Phát hiện tương tác SIGReg $\times$ trạng thái ODE** — nhiễu chống-collapse bị khuếch đại bởi động học liên tục, nguyên nhân thất bại của kiến trúc lai đầu tiên (chi tiết §4.2).
3. **Kiến trúc lai block-level Mamba-2+Attention** — lần đầu tiên Attention và SSM kết hợp trong cùng một khối (Jamba/TransMamba chỉ lai ở mức tầng), lần đầu Mamba-2 trạng thái rời rạc làm bộ dự đoán trong JEPA world model (kết quả §5).

2. Liên quan

JEPA (LeCun 2022) [1]. Joint Embedding Predictive Architecture học cách dự đoán trong không gian tiềm ẩn thay vì tái tạo pixel. Gồm encoder (ảnh $\rightarrow$ latent) và predictor (latent hiện tại + hành động $\rightarrow$ latent tương lai). Loss gồm MSE prediction + một cơ chế chống collapse (SIGReg, VICReg, hoặc stop-grad + EMA).

LeWorldModel (Maes et al. 2026) [2]. Hiện thực hóa JEPA cho world model điều khiển robot. Encoder ViT-tiny 5M, predictor Transformer $6 \times \{\text{Self-Attn} \rightarrow \text{MLP}\}$ 10M. Chống collapse bằng SIGReg [5] — Epps-Pulley test trên các phép chiếu ngẫu nhiên, ép latent về Gaussian. Hai loss: $\text{MSE} + \lambda \cdot \text{SIGReg}$. Đạt 87% TwoRoom, 96% Push-T, 74% Cube, 88% Reacher. Hạn chế: predictor không trạng thái — sai số tích lũy khi horizon tăng.

CfC (Hasani et al. 2022) [3]. Mạng nơ-ron độ sâu liên tục dạng đóng (Closed-form Continuous-depth network) — xấp xỉ nghiệm đúng của ODE LTC. Không cần bộ giải số, có trạng thái ẩn liên tục theo thời gian. Vượt trội thời gian so với RNN/AR (V0: drift 34 lần thấp hơn AR). Paper CfC [3] thừa nhận: "*CfCs might express vanishing gradient problems for long-term dependencies*" — cần mixed memory hoặc Scheduled Sampling (SS).

Mamba-2 (Dao & Gu 2024) [4]. Selective state space model — cải tiến từ Mamba-1 [8] với thuật toán SSD, tận dụng tensor cores, nhanh hơn 2-8 lần. Trạng thái rời rạc, không khuếch đại nhiễu như ODE. Tuy nhiên, Ma & Najarian [6] chứng minh toán học: phụ thuộc xa của Mamba giảm theo **hàm mũ** (exponential memory decay) — thông tin càng xa càng mờ.

Hybrid Attention + SSM. Jamba [9]: xen kẽ Attention và Mamba theo layer. TransMamba [10]: chuyển đổi Attention/SSM theo độ dài chuỗi. Cả hai đều lai ghép ở mức **layer**, chưa có kiến trúc lai ghép **trong cùng một block** (Attention + SSM trong cùng block như công trình này).

Giới hạn chung của world model tiềm ẩn. LeWM paper [2] thừa nhận: "*planning with current latent world models remains restricted to short horizons*". Sai số tích lũy khi tăng planning horizon là hạn chế chung của lớp mô hình này.

3. Phương pháp


3.1. Kiến trúc tổng thể

Mô hình JEPA gồm 3 thành phần: **Encoder** ViT-tiny (5M), patch 14, ảnh 224×224 → CLS token 192-dim; **Predictor** 6 block transformer với causal masking, điều khiển theo hành động qua AdaLN; **Projector + PredProj**: MLP 2 lớp (192→2048→192) + BatchNorm1d.


3.2. Hình A — So sánh 3 kiến trúc bộ dự đoán

Ba kiến trúc dự đoán dùng chung khung dịch vụ (input embedding → self-attention → thành phần lỗi → output), chỉ khác **thành phần lỗi**:


Hình A1: LeWM AR — bộ dự đoán Attention + MLP không trạng thái



Hình A2: Hybrid CfC V1 — Attention + CfC ODE có trạng thái (bị nhiễu $\times$ ODE)




Hình A3: Hybrid Mamba-2 (đề xuất) — Attention + Mamba-2 có trạng thái rời rạc



Mỗi block gồm: (1) AdaLN-modulation — mã hóa hành động + scale/shift từ action embedding; (2) Self-Attention — đa đầu (16 heads, dim_head=64), causal mask; (3) Feed-forward — thay đổi tùy phiên bản.

Kiến trúc block (Mamba2ConditionalBlock):



Hình A4: Sơ đồ khối Mamba2ConditionalBlock — AdaLN điều hòa theo hành động, 2 nhánh residual (màu xám đứt nét)

AdaLN nhận action embedding, xuất 6 giá trị ($\text{shift} \times 3 + \text{scale} \times 3 + \text{gate} \times 3$). Khởi tạo zero để hành động có hiệu lực dần.

Tham số	Giá trị	Ghi chú
depth	6	Số block, bằng LeWM
heads	16	Attention heads
dim_head	64	
d_state	256	SSM state size (LeWM dùng 128)
expand	4	Expansion factor (Mamba-2 internal)

3.3. Hàm mất mát

Loss LeWM: $\mathbf{L} = \text{MSE}(\text{pred_emb} - \text{tgt_emb}) + \lambda \cdot \text{SIGReg}(\text{embeddings})$, với MSE: teacher forcing — dự đoán latent bước tiếp theo; SIGReg [5]: Epps-Pulley test trên random projections, ép latent về Gaussian; $\lambda = 0.09$ từ LeWM paper [2].


3.4. Vì sao chọn Mamba-2

1. **Trạng thái rời rạc** — không khuếch đại nhiễu như ODE CfC
2. **HiPPO initialization** [4] — giá trị riêng bị ràng buộc $\rightarrow$ gradient ổn định (bằng chứng lý thuyết)
3. **Selective scan** — gating phụ thuộc đầu vào $\rightarrow$ lọc nhiễu
4. **Hệ sinh thái hoàn chỉnh** — PyPI wheel, Triton kernel tối ưu, tích hợp HuggingFace — cho phép thí nghiệm nhanh giả thuyết mà không tốn thời gian build từ source. Đây là yếu tố quan trọng vì V1 (CfC) từng mất nhiều thời gian debug ODE kernel, làm chậm vòng nghiên cứu.

4. Hành trình thực nghiệm

4.1. V0 — Robot thật: so sánh CfC và AR

Tôi xây dựng **tay bionic 8-DOF** từ servo SC09, khung in 3D, camera webcam — thiết kế tham khảo DexHand (Rob Knight, 2022) [12]. Mục tiêu: so sánh AR và CfC trên cùng pipeline robot thật.



Hình B1: Robot tay bionic 8-DOF — vị trí neutral, khung in 3D, 8 servo SC09

Vật liệu chế tạo

Bảng 1: Vật liệu và nguồn gốc

Linh kiện	Model	Chức năng	Nguồn gốc
Servo	SC09 (Waveshare)	8 khớp $\times$ 3 ngón đối kháng, bus SCS CL, 300°, 0-1023	Mua mới, linh kiện phổ biến
Khung	PLA in 3D	Kết nối khớp, tham khảo DexHand V1	In tại nhà
Camera	Webcam USB 480p	Quan sát môi trường, CAP_DSHOW	Mua mới, linh kiện phổ biến
Chuyển đổi	USB-UART adapter	UART $\leftrightarrow$ USB + cấp nguồn servo	Mua mới
Nguồn	3 $\times$ 18650	Qua mạch hạ áp $\rightarrow$ 6V	Mua mới

Toàn bộ linh kiện mua được tại các cửa hàng điện tử thông thường — mô hình có thể tái lập với chi phí và dụng cụ hợp lý.



Hình B2: Sơ đồ kết nối phần cứng

Dữ liệu tự thu thập: box kín camera cố định, đèn LED fixed exposure, nền trắng; ~50 episode neutral→grasp, ~8900 frame; augment ColorJitter → ~17800 frame. Phát hiện grasp bằng sai số vị trí $|cmd - actual| < 100$.

Kết quả V0:

Model	Batch	SS	Rollout drift	Gap teacher-rollout
AR-32	32	—	0.2485	71×
AR-264	264	—	0.0012	1.2×
CfC V4	32	—	0.0025	2×
CfC V3	264	0→30%	0.0795	66×

Kết luận V0: CfC temporal vượt trội (drift 0.000014/bước, 34× thấp hơn AR). Scheduled Sampling (SS) cải thiện CfC 29× (0.072→0.0025) — chưa có công bố nào áp dụng SS cho ODE-RNN trước đây. AR không SS, nhưng cần batch >128 để ổn định.

Lưu ý phân định: Kết quả V0 là kiểm chứng **nguyên lý** trên robot thật — dữ liệu tự thu nhỏ (8900 frame, 1 camera, 1 mô hình robot) — chứng minh cơ chế hoạt động (CfC rời trượt thấp hơn AR, chuỗi CEM grasp chạy được). **Đây không phải kết quả thống kê tái lập được.** Kết quả tái lập được (3 seeds × 2 GPU) là V2.1: 94.7% ± 3.1% (Push-T) — xem §5.2 và §8.2.

4.2. V1 — Hybrid CfC+Attention: phát hiện quan trọng

Thay AR predictor bằng CfC trong JEPA: predictor $6 \times \{\text{Self-Attn} \rightarrow \text{CfC}\}$, action conditioning qua AdaLN, loss $\text{MSE} + \lambda \cdot \text{SIGReg}$ ($\lambda=0.09$, num_proj=1024).

Kết quả TwoRoom:

Budget	T	Success rate
50	16	78%
150	16	6%

Kết quả 78% (goal=25, budget 50) → 6% (goal=100, budget 150). CfC vẫn chạy tốt ở goal gần, nhưng chết ở goal xa. So sánh với V0 (cùng CfC + SIGReg $\lambda=0.05$, 20 bước rollout, ổn định): vấn đề là **SIGReg noise tích lũy qua ODE hidden state**. CfC paper [3] thừa nhận: "*CfCs might express vanishing gradient problems for long-term dependencies*". **Kết luận: CfC không tương thích với SIGReg. Cần trạng thái rời rạc.**

4.3. V2.1 — Hybrid Mamba-2+Attention

Thay CfC bằng Mamba-2 (trạng thái rời rạc, không khuếch đại nhiễu). Cùng kiến trúc $6 \times \{\text{Self-Attn} \rightarrow \text{Mamba-2}\}$, cùng loss $\text{MSE} + \lambda \cdot \text{SIGReg}$, cùng config (trừ predictor). Huấn luyện 10 epoch trên Vast RTX 5090 (32GB VRAM), batch 128, bf16, ~5h.

Kết quả và so sánh trên 2 GPU (T4, RTX 5090), 3 seeds — trình bày tại §5 (TwoRoom §5.1, Push-T §5.2); kiến trúc lai block-level cũng là đóng góp chính đã tóm tắt tại §1.


5. Kết quả

Từ giả thuyết ở §1 đến đây, tám lần thiết kế — CfC, công thức, SIGReg — đã thay 6. Mỗi thử nghiệm dưới đây là bằng chứng thật, so trong cùng điều kiện: cùng 3 seeds, cùng cấu hình $H=K=5$, cùng eval.py; LeWM đối chiếu từ 3 nguồn (GitHub, local, paper).

5.1. TwoRoom

Model	Budget	Goal	Success rate (3 seeds)	Ghi chú
Hybrid Mamba-2	50	25	85.3% $\pm$ 10.1% (84,76,96)	T4 fp32, 3 seeds
Hybrid Mamba-2	50	25	86.0% $\pm$ 10.0%	RTX 5090, 3 seeds
LeWM official	50	25	80.7% $\pm$ 10.3% (78,72,92)	T4 fp32, 3 seeds
LeWM official	50	25	81.3% $\pm$ 9.5%	RTX 5090, 3 seeds
LeWM paper [2]	50	25	87%	Tham khảo (GPU khác)

So sánh ở mức budget 150, goal=100: Hybrid đạt 18% (9/50).



Hình C: Môi trường TwoRoom. Nguồn: [2]

5.2. Push-T

Seed	Success rate
3072	92% (46/50)
3073	98% (49/50)
3074	94% (47/50)
Mean $\pm$ std	94.7% $\pm$ 3.1%


Model	GPU	Success	Seeds
Hybrid Mamba-2	T4 fp32	94.7% $\pm$ 3.1% (92,98,94)	3072,3073,3074
Hybrid Mamba-2	RTX 5090	94.7% $\pm$ 3.1% (94,98,92)	3072,3073,3074
LeWM official (3 seeds)	T4 fp32	86.0% $\pm$ 4.0%	3072,3073,3074
LeWM official (3 seeds)	RTX 5090	88.0% $\pm$ 4.0% (88,92,84)	3072,3073,3074
LeWM paper [2]	(không rõ)	96% $\pm$ 2.83%	—

Hybrid Mamba-2 vượt LeWM AR trên cùng GPU: +6.7% (5090), +8.7% (T4) với 3 seeds cho cả hai model. So với số paper (96% $\pm$ 2.83%), kết quả nằm trong khoảng tin cậy chồng lấp. Kết quả tái lập trên 2 GPU khác nhau (T4 + RTX 5090) đều **94.7%** — không phụ thuộc phần cứng.



Hình D: Môi trường Push-T. Nguồn: [2]

5.3. Đồ thị huấn luyện



Hình E: Training curve Push-T — *val_pred* giảm 57% qua 8 epoch; SIGReg plateau từ epoch 6

5.4. Thử nghiệm với các tầm nhìn dài hơn


H	LeWM AR	Hybrid Mamba-2	Ghi chú
5	86.0% ± 4.0%	94.7% ± 3.1%	Hybrid vượt trội
10	40%	42%	Sai số tích lũy bắt đầu ảnh hưởng cả hai
20	4%	2%	Cả hai gần như ngẫu nhiên — giới hạn chung latent WM

LeWM paper [2] thừa nhận: *"auto-regressive rollouts accumulate prediction errors as the horizon grows"* — và Hybrid Mamba-2 cũng chịu chung giới hạn này.

5.5. Thời gian giải kế hoạch bằng CEM

Model	GPU	First episode	Post-compile/ep
LeWM AR (3 seeds)	T4 fp32	~98s (cuDNN init)	~20s
LeWM AR (3 seeds)	RTX 5090	—	~43s/50ep
Hybrid Mamba-2	T4 fp32	~1160s (Triton kernel compile lần đầu)	~85s
Hybrid Mamba-2	RTX 5090	—	~107s

Hybrid chậm hơn LeWM $\sim 4 \times (T4) / \sim 2.5 \times (RTX\ 5090)$ — phân tích hạn chế xem §6.4.



Hình F: CEM planning trong latent space — 300 chuỗi hành động được mô phỏng trong MÔ HÌNH

6. Thảo luận

6.1. ODE vs Discrete State — nguồn gốc khác biệt

Config	Goal	Budget	CfC (T=16, heads=8)	Mamba-2 (T=4, heads=16)	Ghi chú
H=5, K=5	25	50	78%	86%	Cùng goal, budget — CfC thấp hơn
H=5, K=5	100	150	6%	18%	Goal xa 4×, cả hai đều giảm

Khi goal xa hơn, cả CfC và Mamba đều giảm — CfC 78%→6%, Mamba 86%→18%. Dù dùng T và heads khác nhau (mỗi kiến trúc tối ưu riêng), ở cùng điều kiện eval (goal=100, budget=150) Mamba-2 (18%) cao hơn CfC (6%) — khoảng cách này phù hợp với phân tích ODE khuếch đại SIGReg noise.

Cơ chế: SIGReg [5] tạo nhiễu trong latent embeddings. Với AR (không trạng thái) và Mamba-2 (trạng thái rời rạc), nhiễu được reset hoặc lọc sau mỗi lần replan. Với CfC, nhiễu tích lũy trong ODE

hidden state qua nhiều lần replan. Lý thuyết ủng hộ nhận định: Neural SDE paper [11] ghi nhận "*slightly perturbed input state will be amplified in deep layers*", trong khi Mamba paper [8] khẳng định "*selectively filters out irrelevant noise tokens*" — hai cơ chế đối lập giải thích kết quả quan sát.

Lưu ý: CfC không yếu về temporal — đã kiểm chứng trên robot thật (V0, xem §4.1). CfC chỉ không tương thích với SIGReg, không phải CfC kém.

6.2. Sai số tích lũy ở H lớn — giới hạn chung

Khi tăng H từ 5 lên 10, cả LeWM AR ($86.0\% \pm 4.0\% \rightarrow 40\%$) và Hybrid Mamba-2 ($94.7\% \pm 3.1\% \rightarrow 42\%$) đều giảm mạnh. Ở $H=20$, cả hai gần ngẫu nhiên (4% và 2%). Điều này xác nhận giới hạn của world model tiềm ẩn với planning dài hạn, như LeWM paper [2] thừa nhận trong Limitations: "*planning with current latent world models remains restricted to short horizons*".

Nguyên nhân: CEM rollout H bước trong latent space không có observation correction — sai số từ dự đoán tích lũy qua H bước $\rightarrow$ cost tính từ latent cuối sai $\rightarrow$ CEM chọn action sai. MPC (receding horizon K) chỉ giảm thiểu, không loại bỏ. Đáng chú ý: cơ chế này giống Scheduled Sampling (SS) đã dùng cho CfC ở V0 — cả hai giải quyết sai số tích lũy bằng cách "thường xuyên hiệu chỉnh bằng ground truth." SS ở training, K ở inference — cùng một ý tưởng nhất quán.

Riêng với Mamba-2, Ma & Najarian [6] chứng minh phụ thuộc dài giảm theo hàm mũ — rào cản phụ cho planning dài hơn.

6.3. So sánh với LeWM

Kết quả của Hybrid nằm trong khoảng tin cậy chồng lấp với số paper ($96\% \pm 2.83\%$) — cho thấy kiến trúc KHÔNG thua kém dù bị hạn chế về phần cứng so với paper, và tái lập ổn định trên 2 GPU với cùng cấu hình (số liệu bảng §5.2, §5.4).

6.4. Hạn chế

1. **CEM solve time:** $\sim 85s/ep$ vs LeWM $\sim 20s/ep$ trên T4 (chậm $\sim 4\times$) và $\sim 107s$ vs $\sim 43s/50ep$ trên RTX 5090 (chậm $\sim 2.5\times$) — đã đo trên 2 GPU, cùng seed và cấu hình. Đây là trade-off thực tế của Mamba-2 Triton kernel so với attention kernel đã tối ưu sẵn của LeWM. Dư địa cải thiện: (i) dùng torch.compile để biên dịch tổng mô hình; (ii) chỉnh Mamba-2 kernel cho GPU cụ thể; (iii) hướng triển khai §7.2 bỏ hẳn solver, thay bằng phản xạ 1 forward (vài ms).
2. **Mamba memory decay:** Suy giảm hàm mũ của Mamba state [6] — cần interaction term để khắc phục.
3. **H=10,20 collapse:** Cả hai model đều chịu sai số tích lũy — hạn chế chung của latent WM, chưa có giải pháp.
4. **TwoRoom variance cao:** Std $\pm 10.1\%$ (Hybrid) và $\pm 10.3\%$ (LeWM) với 3 seeds. Cần thêm seeds để khẳng định xu hướng.

6.5. Cân nhắc khi triển khai

Hạn chế về thời gian giải kế hoạch cần được cân nhắc bối cảnh triển khai:

- **Mamba-2 vốn dùng thuật toán SSD tận dụng tensor-core matmul** [4] — nhanh 2-8 $\times$ so với Mamba-1, và độ phức tạp xử lý **near-linear** với độ dài chuỗi, trong khi Attention có độ phức tạp $O(N^2)$. Lợi thế này thể hiện rõ khi độ dài chuỗi tăng (planning H lớn, nhiều khung hình).
- Tuy nhiên, **kết quả thời gian của nghiên cứu này đạt được trên T4 fp32 và RTX 5090** — Mamba-2 Triton kernel khai thác tốt hơn trên GPU hiện đại (chậm $\sim 2.5\times$ trên 5090 so với $\sim 4\times$

trên T4). **Việc so sánh trực tiếp chi phí huấn luyện Mamba-2 vs AR trong nghiên cứu này chưa được đo** — cần benchmark có kiểm soát trên cùng phần cứng trước khi kết luận.

- Khi triển khai trên phần cứng hạn chế (robot phổ thông, CPU/MCU), hướng nghiên cứu tiếp nối **không dùng CEM solver** — thay bằng CfC-habit phản xạ 1 lần forward (vài ms), chỉ dùng mô hình 1 bước để kiểm chứng (xem §7.2, §6.2). Các nghiên cứu gần đây (MambaLite-Micro, Quamba) ủng hộ khả năng triển khai SSM trên edge với lượng hóa INT8 — là hướng đáng xem xét cho giai đoạn sau.

7. Kết luận và hướng nghiên cứu tiếp nối


7.1. Kết luận

Nghiên cứu đề xuất **Hybrid Mamba-2+Attention** — kiến trúc lai thay MLP không trạng thái (LeWM AR) bằng Mamba-2 trạng thái rời rạc trong bộ dự đoán JEPA, và kể một hành trình nghiên cứu trọn vẹn: từ robot thật (V0), qua một thất bại có giá trị (V1 — phát hiện SIGReg tương tác xấu với trạng thái ODE), đến kiến trúc thắng ở H=5 trên cùng điều kiện (V2.1: Push-T $94.7\% \pm 3.1\%$ so với LeWM $88.0\% \pm 4.0\%$ trên RTX 5090 và $86.0\% \pm 4.0\%$ trên T4 — khoảng cách tái lập trên 2 GPU, 3 seeds).

Trộn bộ ba đóng góp — Scheduled Sampling cho CfC ($29\times$), phát hiện SIGReg $\times$ ODE, kiến trúc lai block-level — được trình bày ở §1 và chi tiết ở §4-§6. Trong viễn cảnh triển khai, CEM planning chậm $\sim 2.5\times$ (RTX 5090) là trade-off có thể chấp nhận được để đổi lấy độ chính xác cao hơn, và được khắc phục một phần bằng chiến lược thay solver bằng phản xạ nhanh (CfC-habit) ở hướng tiếp nối §7.2.

7.2. Hướng nghiên cứu tiếp nối: robot nhặt rác di động

Kết quả của nghiên cứu mở ra hướng ứng dụng thực tế lớn hơn: **robot nhặt rác di động** — bài toán có ý nghĩa xã hội và môi trường, được dự kiến triển khai trong thời gian tới.



Hình H: Sơ đồ khối hệ thống robot nhặt rác — hướng nghiên cứu tiếp nối. Camera → MobileNetV2 (nhận diện rác) → HOMING (u^*, v^*, s^* — căn chỉnh điểm grasp); LiDAR+IMU → EKF → Nav2 (định vị, di chuyển); Servo SC09 (góc + lực — tín hiệu thành công). CfC-habit (phản xạ) + CfC-imagination (verifier mô hình 1 bước); OOD gate so với z_{goal} (cố định) sinh $\alpha = \text{sigmoid}(\text{OOD})$ → pha trộn với điều khiển giải tích. Mũi tên đứt nét = luồng cập nhật khi học: SI giữ trọng số, Kênh A tự học (SUCCESS qua SC09), Kênh B teleop. Phần cứng: khung chassis, 2 cụm 3S, 2 buck 5V, L298N.

Bản thiết kế tận dụng ba kết quả chính của nghiên cứu: - **CfC-habit (phản xạ)** — học lệnh điều khiển từ người, tạo bộ điều khiển phản xạ nhanh thay cho CEM solver nặng (mô hình 16.6M tham số này đã học trên robot thật ở V0); - **CfC-imagination (mô hình 1 bước)** — đúc kết từ chính mô hình dự đoán thế giới trong nghiên cứu, dùng để "cuộn phim trước" kiểm chứng hành động; - **OOD gate (tự biết lạ)** — đưa phát hiện SIGReg×ODE vào ứng dụng thực tế: robot tự nhận biết trạng thái ngoài phân phối và điều chỉnh độ tin cậy.

Chuỗi vận hành: robot tìm rác (SEARCH) → di chuyển tới gần (NAV) → căn chỉnh điểm grasp bằng homing (ALIGN) → hạ tay và khớp kẹp với 4 mức xác nhận (GRASP: camera thấy rác tại điểm cố định → tín hiệu lực và góc khớp từ servo → giám sát khi nâng) → bỏ rác vào thùng (LIFT + DROP).

Khi gặp dữ liệu lạ, hệ thống tuân theo 5 bước: (1) nhận ra lạ — OOD và mô hình kiểm chứng cùng báo động; (2) an toàn — α giảm về 0, robot chuyển sang điều khiển giải tích thuần và thử lại; (3) học lại — cập nhật cục bộ từ kênh tự động (các lần thành công) kèm giữ trọng số gần bản gốc; (4) quen dần — ngưỡng nhận biết lạ tăng lên, độ tin cậy α phục hồi dần; (5) mù hẫn — robot kêu gọi người thao tác, không bao giờ hổng im lặng. Mục tiêu z_{goal} và phần thân cơ sở cố định trong suốt quá trình học.

Bản thiết kế này là **hướng nghiên cứu tiếp nối** — kêu gọi khai thác thực nghiệm trên nền robot thật, và thể hiện tính liên tục của hành trình nghiên cứu (từ V0 robot tay thật → V2.1 đạt chuẩn benchmark → V2.5.2 đẩy vào ứng dụng thực tế).

Về mặt ý nghĩa thực tế, một robot nhặt rác di động có thể được triển khai tại trường học, khuôn viên công cộng hoặc sân chơi — những nơi rác nhỏ như vỏ chai, nilon còn rơi vãi hằng ngày. Điểm đáng chú ý là toàn bộ hình thái và triết lý "reflex + tự biết lạ + học không quên" được minh họa bằng mô hình nhỏ, có thể tái tạo bởi học sinh — mở ra khả năng nhân rộng tại nhiều trường cùng đam mê kỹ thuật, thay vì một sản phẩm đắt đỏ chỉ mua được một lần.

Cam kết tiến độ: nghiên cứu tiếp nối dự kiến hoàn thành trong **6 tuần** khi được hỗ trợ tiếp tục hoàn thiện.

8. Cách sử dụng, vận hành

8.1. [V0 — Robot thật] Vận hành phần cứng theo cử chỉ (demo)

Chạy demo teleop điều khiển tay bionic theo cử chỉ bàn tay người:

```
python demo_grasp.py
```

8.1.2. [V0 — Robot thật] Vận hành world model + CEM trên robot thật

```
python robot_planner.py --goal <file> --model cfc --checkpoint <ckpt>
```

Chuỗi hoạt động: camera → encoder → CEM 300 chuỗi × 30 vòng → chọn action tối ưu → servo thực hiện → kiểm tra vị trí — grasp phát hiện thành công.

```
Step 0: cost=1.124523
CEM iter 1/5: cost=0.342302 (best=0.342302)
CEM iter 3/5: cost=0.247082 (best=0.247082)
CEM iter 5/5: cost=0.211920 (best=0.211920)
Plan (H=3): {1: 320, 2: 47, 4: 603, 5: 355, 6: 909, 7: 947, 8: 408, 9: 688}
Position: S2:cmd=289 actual=288 err=1 GRASP | S4:cmd=310 actual=318 err=8 GRASP | S7:cmd=501 actual=507 err=6 GRASP
✅ All 3 servos at target — grasp detected
```

Hình 1: Log terminal thật — CEM planning chạy trên robot V0: Step 0 → CEM iter → Plan H=3 → báo GRASP

8.2. [V2.1 — Benchmark mô phỏng] Tái lập kết quả eval

```
python eval.py --config-name=pusht policy=<ckpt> --seed=3072 --config-name=pusht
```

Kết quả tái lập 3 seeds trên 2 GPU (T4/RTX 5090): 92%, 98%, 94% → 94.7% ± 3.1% (Push-T). Mã nguồn và checkpoint công khai:

Thành phần	Liên kết
 Mã nguồn	github.com/thoan4965-ui/hybrid-mamba-2-attention-world-model
 Checkpoint	huggingface.co/hhian/checkpoints

Phân định rõ hai kết quả: Mục 8.1 là kết quả [V0 — robot thật] — tay bionic tự chế, dữ liệu tự thu nhỏ (8900 frame, 1 camera): đây là kiểm chứng nguyên lý (drift 34× thấp hơn AR, grasp

chạy được chuỗi CEM thật), **không phải kết quả thống kê tái lập được** vì dữ liệu nhỏ và chỉ trên 1 mô hình robot. Mục 8.2 là kết quả [V2.1 — benchmark mô phỏng] với dữ liệu chuẩn (20K episode), $3 \text{ seeds} \times 2 \text{ GPU}$ — tái lập được đầy đủ: $94.7\% \pm 3.1\%$ (Push-T).



Hình J: Ảnh thật robot đang grasp chai nước trong box thu dữ liệu

9. Tài liệu tham khảo

#	Nguồn
[1]	LeCun, Y. (2022). A Path Towards Autonomous Machine Intelligence.
[2]	Maes, L., Le Lidec, Q., Scieur, D., LeCun, Y., Balestrieri, R. (2026). LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels. arXiv 2603.19312.
[3]	Hasani, R. et al. (2022). Closed-form Continuous-time Neural Networks. Nature Machine Intelligence.
[4]	Dao, T. & Gu, A. (2024). Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality. ICML 2024.
[5]	Balestrieri, R. & LeCun, Y. (2025). LeJEPA: Provable and Scalable Self-Supervised Learning Without the Heuristics. arXiv 2511.08544.
[6]	Ma, C. & Najarian, K. (2025). Rethinking the long-range dependency in Mamba/SSM and transformer models. arXiv 2509.04226.
[7]	Huang, Y. (2026). VJEPA: Variational Joint Embedding Predictive Architectures as Probabilistic World Models. arXiv 2601.14354.
[8]	Gu, A. & Dao, T. (2023). Mamba: Linear-Time Sequence Modeling with Selective State Spaces. arXiv 2312.00752.
[9]	Lieber, O. et al. (2024). Jamba: A Hybrid Transformer-Mamba Language Model.
[10]	Li, Y. et al. (2026). TransMamba: A Sequence-Level Hybrid Transformer-Mamba Language Model. AAAI 2026.
[11]	Liu, X. et al. (2020). Neural SDE: Stabilizing Neural ODE Networks with Stochasticity. NeurIPS 2020.
[12]	Rob Knight (2022). DexHand V1.0: Open-Source Dexterous Humanoid Robot Hand. GitHub.
[13]	Xu, H. et al. (2025). MambaLite-Micro: Memory-Optimized Mamba Inference on MCUs. arXiv 2509.05488.
[14]	Chiang, H.-Y. et al. (2025). Quamba: A Post-Training Quantization Recipe for Selective State Space Models. ICLR 2025.